

Processo Seletivo - Engenheiro de Dados Jr

Geofusion

1. Objetivo

Desenvolver uma solução analítica capaz de responder às seguintes perguntas de negócio:

- Qual é a faixa de preço praticada pelos concorrentes?
- Como é o fluxo de pessoas segmentado por dia da semana e período do dia?
- Qual é a população e a densidade demográfica dos bairros onde os concorrentes estão localizados?

A solução foi implementada em etapas estruturadas nos notebooks do projeto.

2. Exploração dos Dados (01_exploracao.ipynb)

Nesta etapa foram realizadas:

- Leitura dos arquivos CSV e JSON
- Inspeção de colunas e tipos
- Identificação de valores nulos
- Análise inicial de consistência
- Verificação de chaves de relacionamento (código de bairro, código de concorrente)

Foram identificados:

- Necessidade de conversão de tipos (datas e numéricos)
 - Valores nulos na população
 - Campos que exigiam padronização
-

3. Tratamento dos Dados (02_tratamento.ipynb)

Nesta fase foram aplicadas transformações estruturais:

Correção de Tipagem

- Conversão de datas para datetime
- Conversão de códigos para inteiros
- Conversão de valores monetários para float

Tratamento de Nulos

- Validação de registros essenciais
- Ajuste ou exclusão de registros inconsistentes

Padronização

- Normalização de nomes de colunas
- Garantia de integridade referencial

Após o tratamento, os dados foram salvos em formato **Parquet** na camada `trusted_silver`, garantindo melhor performance para análises posteriores.

4. Cálculo das Métricas (03_metrics.ipynb)

4.1 Faixa de Preço

Foi utilizada agregação por concorrente para calcular:

- Preço mínimo
- Preço máximo
- Preço médio

Resultado armazenado na estrutura analítica final.

4.2 Fluxo de Pessoas

A modelagem incluiu:

- Extração do dia da semana a partir da data da visita
- Extração da hora
- Classificação do período:
 - Manhã (06h-12h)
 - Tarde (12h-18h)
 - Noite (18h-06h)

Foram calculadas métricas por:

- Concorrente
- Dia da semana
- Período

Incluindo:

- Média de visitas
- Máximo
- Mínimo

Esses dados foram consolidados em:

`fluxo_concorrente_analitico.parquet`

4.3 População e Densidade Demográfica

A base de população (`populacao`) foi integrada aos dados de bairros.

A densidade foi calculada como: $\text{densidade_demografica} = \text{populacao} / \text{area_km2}$

O resultado foi salvo em:

`concorrente_geografia.parquet`

5. Visualizações (04_dataviz.ipynb)

Foram geradas visualizações para:

- Distribuição de fluxo por dia da semana
- Comparação de períodos (manhã, tarde, noite)
- Análise exploratória de densidade demográfica

Essas visualizações auxiliam na interpretação estratégica dos dados.

6. Estrutura Analítica Final

Foram gerados dois principais artefatos:

1. `fluxo_concorrente_analitico.parquet`

Contém:

- Código do concorrente
- Dia da semana
- Período
- Média, máximo e mínimo de visitas

2. `concorrente_geografia.parquet`

Contém:

- Código do concorrente
- Código do bairro
- População
- Área
- Densidade demográfica

Formato adotado: **Parquet**

Motivação:

- Armazenamento colunar
 - Melhor compressão
 - Alta performance de leitura
 - Compatibilidade com engines distribuídas
-

7. Uso do DuckDB

DuckDB foi utilizado para:

- Executar consultas SQL diretamente sobre arquivos Parquet
- Validar agregações

- Testar joins analíticos

Isso permitiu trabalhar de forma performática sem necessidade de banco externo.

8. Considerações de Engenharia

O projeto foi estruturado com foco em:

- Separação entre dados brutos e dados tratados
- Reprodutibilidade das transformações
- Facilidade de reprocessamento
- Geração de artefatos analíticos consolidados

A estrutura permite evolução para:

- Processamento incremental
 - Orquestração automatizada
 - Execução distribuída (Spark)
 - Armazenamento em Data Lake
-

9. Ambiente e Dependências

O projeto foi desenvolvido em ambiente Python, com controle explícito de dependências conforme definido em `requirements.txt`.

Principais bibliotecas utilizadas:

- pandas ($\geq 1.5.0$) - Manipulação e transformação de dados
- numpy ($\geq 1.23.0$) - Operações numéricas
- duckdb ($\geq 0.9.0$) - Execução de SQL sobre arquivos Parquet
- pyarrow ($\geq 12.0.0$) - Suporte a leitura e escrita em Parquet
- matplotlib ($\geq 3.7.0$) - Visualizações básicas
- seaborn ($\geq 0.12.0$) - Visualizações estatísticas

Essa escolha tecnológica permitiu:

- Processamento eficiente em ambiente local
 - Execução de consultas analíticas sem necessidade de banco externo
 - Geração de visualizações exploratórias
 - Armazenamento otimizado em formato colunar
-

Considerações Finais

O projeto foi estruturado de forma modular e organizada, contemplando:

- Exploração e validação inicial dos dados
- Tratamento e padronização com controle de tipagem
- Cálculo de métricas analíticas consolidadas
- Geração de artefatos finais em formato otimizado
- Validação via SQL utilizando DuckDB

A solução atende integralmente aos requisitos do desafio, demonstrando capacidade de:

- Estruturar pipelines analíticos

- Garantir qualidade e consistência dos dados
- Projetar arquitetura escalável
- Preparar a solução para evolução futura em ambiente distribuído